Projet de Traducteur Multilingue (Français, Anglais, Ewe) avec Reconnaissance Vocale

Objectif : Développer un système de traduction automatique et vocale prenant en compte le français, l'anglais et l'ewe (langue locale du Togo), en utilisant des techniques de NLP (Natural Language Processing) et de machine learning.

1. Objectifs du Projet

- Collecter des données textuelles et audio en français, anglais et ewe via du scraping web.
- Prétraiter les données (nettoyage, tokenisation, alignement des corpus).
- Entraîner un modèle de traduction automatique (seq2seq, Transformer) pour les paires :
  - Français ↔ Anglais
  - Français ↔ Ewe
  - Anglais ↔ Ewe
- Intégrer une reconnaissance vocale (STT - Speech-to-Text) pour la traduction orale.
- Développer une interface utilisateur (Web ou Mobile) pour tester le traducteur.

2. Étapes du Projet

a. Collecte des Données (Scraping & Corpus)

- Sources :
  - Textes bilingues (sites gouvernementaux, livres, articles).
  - Podcasts/interviews en ewe (YouTube, archives radio).
  - Bases de données ouvertes (OPUS, JW300 pour l'ewe si disponible).
- Outils :
  - Scraping : BeautifulSoup, Scrapy, YouTube API (pour transcriptions).
  - Stockage : CSV/JSON ou base de données (textes alignés).

b. Prétraitement des Données

- Nettoyage :
  - Suppression des caractères spéciaux, normalisation Unicode.
  - Découpage en phrases (tokenization avec NLTK, spaCy).
- Alignement des phrases (pour les paires de langues) :
  - Outils : ‘fast_align’, ‘GIZA++’ (si corpus non aligné).
- Augmentation des données (si corpus ewe insuffisant) :
  - Back-translation (français → anglais → ewe).

c. Modèle de Traduction Automatique

- Approches possibles :
  - Réseaux de neurones seq2seq (LSTM/GRU avec attention).
  - Transformers (Hugging Face, FairSeq).
- Entraînement :
  - Fine-tuning d'un modèle pré-entraîné (mBART, NLLB de Meta).

- Custom Transformer avec PyTorch/TensorFlow.
- Évaluation :
  - Métriques : BLEU, ROUGE (pour comparer avec Google Translate en ewe).

d. Reconnaissance Vocale (Optionnel)

- Module STT (Speech-to-Text) :
  - Utiliser Whisper (OpenAI) ou Wav2Vec (Facebook) pour transcrire l'audio.
  - Adapter le modèle pour l'ewe (fine-tuning si données audio disponibles).
- Synthèse vocale (TTS - Text-to-Speech) :
  - Utiliser Coqui TTS ou Google TTS (si voix ewe disponible).

e. Interface Utilisateur

- Choix possibles :
  - Application Web : Flask/Django + HTML/JS.
  - Application Mobile : Flutter/React Native.
- Fonctionnalités :
  - Saisie texte + traduction instantanée.
  - Enregistrement vocal → traduction écrite/orale.
  - Historique des traductions.

3. Livrables Attendus

1. Jeu de données bilingue/triilingue (français, anglais, ewe).
2. Modèles entraînés (traduction et STT si applicable).
3. Code source (notebooks, scripts, interface).
4. Rapport technique (méthodologie, performances, limites).
5. Démo fonctionnelle (vidéo ou lien web).

4. Technologies Recommandées

- Langages : Python (PyTorch/TensorFlow).
- Librairies NLP : Hugging Face Transformers, spaCy, NLTK.
- Traitement audio : Librosa, Whisper, Wav2Vec.
- Interface : Streamlit (rapide), Flask/Django (plus complet).
- Collaboration : Git/GitHub.

5. Défis & Solutions Potentielles

- Manque de données en ewe :
  - Utiliser des techniques de transfer learning (modèles multilingues).
  - Collaborer avec des locuteurs ewe pour annoter des phrases.
- Traduction de l'ewe :
  - Commencer par des phrases simples (dataset ciblé).
  - Utiliser des règles linguistiques (dictionnaires ewe-français).

Durée estimée : 6 semaines (selon disponibilité des données).

Équipe idéale : 4-5 personnes (scraping, NLP, audio, frontend).

Ce projet permettra de combler un manque dans la traduction automatique pour les langues africaines, tout en explorant des défis techniques en NLP et traitement vocal.

Date de début : 06 Mai 2026
Présentation : 19 juin 2026