Master 1 IA-BD — EPL

Cours INF2229 • Informatique et Gestion de Données

MiaGbe – Traducteur Multilingue

FR • EN • ÉWÉ

avec reconnaissance et synthèse vocales

RAPPORT TECHNIQUE

Réalisé par — Groupe GR02

AZIGLOSSOU Judith Gracia • NAPO NISSAO Rafia

WOGLO Koffi Boris Gilbride • PIO Sikirou Afeez Prince Cyrille

KOMBATE Gountande

Encadré par

Dr. Akouyo Yvette GBEDEVI

Année universitaire 2025 – 2026

Résumé

Ce projet réalise un système de traduction automatique **multidirectionnel** entre le français, l'anglais et l'éwé — langue gbe parlée au Togo et au Ghana, fortement sous-dotée en ressources numériques. Le système couvre les **six** directions de traduction possibles et il est complété d'une **chaîne vocale** de bout en bout (reconnaissance et synthèse), l'éwé compris.

L'approche méthodologique privilégie le **transfert d'apprentissage** : plutôt que d'entraîner un modèle depuis zéro, on adapte un grand modèle multilingue pré-entraîné, **NLLB-200** de Meta, à l'aide d'un adaptateur **LoRA** (*Low-Rank Adaptation*). Le modèle est affiné sur un corpus trilingue de près de **700 000 paires** de phrases alignées, nettoyées et filtrées, puis enrichi par **back-translation** : cette augmentation améliore nettement les directions vers l'éwé et est retenue pour le modèle final.

L'évaluation, conduite à la fois sur un jeu interne et sur le jeu de référence international **FLORES-200**, montre que l'adaptateur améliore les **six directions sans aucune régression**, avec un gain moyen de **+1,24 point BLEU** et **+1,64 point chrF** par rapport au modèle de base. La solution est exposée via une API FastAPI et une interface web React.

Contribution principale. Un traducteur trilingue opérationnel pour une langue peu dotée, accompagné d'une méthodologie de données rigoureuse (alignement, filtrage, contrôle du biais) et d'une évaluation sur benchmark externe — démontrant un apport mesurable du fine-tuning tout en documentant ses limites.

Sommaire

Résumé **1**

1 Introduction et contexte **3**
1.1 Problématique . . . 3
1.2 Objectifs . . . 3
1.3 Choix de conception . . . 3

2 Architecture générale **5**

3 Construction du corpus **6**
3.1 Sources . . . 6
3.2 Nettoyage et normalisation . . . 7
3.3 Alignement et filtrage du bruit . . . 7
3.4 Tokenisation . . . 7
3.5 Découpage et volumétrie . . . 7
3.6 Contrôle du biais . . . 8

4 Modèle de traduction **9**
4.1 Modèle de base : NLLB-200 . . . 9
4.2 Adaptation par LoRA . . . 9
4.3 Dynamique d’entraînement . . . 9
4.4 Augmentation par back-translation . . . 10

5 Évaluation **11**
5.1 Métriques . . . 11
5.2 Protocole . . . 11
5.3 Résultat principal : base vs LoRA sur FLORES-200 . . . 11
5.4 Test interne . . . 12
5.5 Apport de la back-translation . . . 12
5.6 Analyse . . . 13

6 Chaîne vocale **15**

7 Interface et API **16**

8 Limites et perspectives **17**
8.1 Limites . . . 17
8.2 Perspectives . . . 17

9 Conclusion **18**

1 Introduction et contexte

1.1 Problématique

La traduction automatique a connu des progrès spectaculaires pour les langues dites « à haute ressource » (anglais, français, etc.), mais les centaines de langues africaines restent largement en marge de ces avancées. L'**éwé** (autonyme *Eʋegbe*), parlé par plusieurs millions de locuteurs au Togo et au Ghana, en est un exemple représentatif : il dispose de très peu de corpus numériques, et les rares données disponibles sont souvent bruitées, mal alignées, ou cantonnées à un domaine unique (textes religieux notamment).

Ce projet s'attaque directement à ce déséquilibre en construisant un traducteur couvrant les trois langues du sujet et leurs six directions, avec une attention particulière portée à la **qualité des données** et à une **évaluation rigoureuse** — les deux conditions sans lesquelles un score chiffré n'a pas de sens pour une langue peu dotée.

1.2 Objectifs

Conformément au cahier des charges, le système couvre l'intégralité de la chaîne de traitement :

— **Collecter** des corpus parallèles dans les trois langues à partir de sources ouvertes et de qualité contrôlée.

— **Prétraiter** les données : nettoyage, normalisation Unicode, tokenisation et alignement des phrases.

— **Entraîner** un modèle de traduction neuronale pour les paires Français ↔ Anglais, Français ↔ Éwé et Anglais ↔ Éwé.

— **Intégrer** une reconnaissance vocale (STT) et une synthèse vocale (TTS) pour la traduction orale.

— **Développer** une interface web permettant de tester le traducteur (saisie texte, dictée, écoute, historique).

1.3 Choix de conception

Trois décisions structurent l'ensemble du travail. Premièrement, le recours au **transfert d'apprentissage** depuis un modèle massivement multilingue : c'est la réponse recommandée par la littérature face au manque de données. Deuxièmement, la priorité donnée au **nettoyage et au filtrage** du corpus, car sur une langue peu dotée le bruit pèse davantage qu'un modèle plus gros. Troisièmement, une **évaluation sur bench-**

mark externe (FLORES-200) afin d’obtenir des chiffres comparables et clairs, et non flattés par la proximité au domaine d’entraînement.

2 Architecture générale

Le projet est organisé en quatre blocs indépendants et reproductibles, qui se transmettent leurs sorties par fichiers. Cette séparation permet de relancer une étape sans rejouer les précédentes, et de tracer précisément l'origine de chaque résultat.

1. **Construction des données** — `notebooks/00_donnees.ipynb`. Collecte, nettoyage, alignement, filtrage et découpage. Produit le corpus final dans `data/processed/nllb/` (fichiers `nllb_train.csv`, `nllb_valid.csv`, `nllb_test.csv`).
2. **Modèle de traduction** — `notebooks/01_pipeline_nllb_lora.ipynb`. Fine-tuning LoRA de NLLB-200, suivi des pertes, évaluation BLEU/chrF et comparaison base vs adaptateur sur FLORES-200.
3. **Augmentation** — `notebooks/02_backtranslation_nllb_lora.ipynb`. Génération de données synthétiques par back-translation, ré-entraînement dans un dossier séparé et comparaison systématique avant adoption.
4. **Service applicatif** — `src/traducteur/`. API FastAPI (endpoints de traduction, transcription, synthèse, historique) et interface React/Vite.

Pile technologique. Python, PyTorch, Hugging Face Transformers et PEFT pour le modèle ; `sacrebleu` pour l'évaluation ; `librosa`, Whisper et MMS pour l'audio ; FastAPI (backend) et React/Vite (frontend) ; Git/GitHub pour la collaboration. Ces choix correspondent aux technologies recommandées par le sujet.

3 Construction du corpus

La qualité du corpus est le facteur déterminant pour une langue peu dotée. Le notebook de données enchaîne sept étapes, de la collecte au bilan final.

3.1 Sources

Le corpus combine plusieurs jeux ouverts, choisis pour leur licence et leur niveau de qualité, et répartis en deux familles :

— **Sources « propres » (humaines)** : **google/SMOL** (traductions professionnelles en–ee), **FLORES** (découpage `dev`, aligné dans les trois langues), **MAFAND** (fr–ewe, actualités, projet Masakhane). Elles entrent directement dans le corpus.

— **Sources web-minées** : OPUS (NLLB, TED2020, Tatoeba, News-Commentary, translatewiki) et une part biblique. Plus volumineuses mais plus bruitées, elles passent par tout le pipeline de durcissement décrit ci-dessous.

Toutes ces sources sont des **données secondaires** : des corpus publics déjà constitués par des tiers. Le projet ne réalise pas de collecte *primaire* (ni scraping de nouveaux sites, ni enregistrements) — c'est la voie « bases de données ouvertes » prévue par le cahier des charges. Trois canaux d'accès sont utilisés : le dépôt **OPUS** (`opus.nlpl.eu`, téléchargement direct), la bibliothèque **Hugging Face** `datasets`, et **GitHub**.

Source	Langues	Producteur / nature	Accès
OPUS-NLLB	ee–fr, en–ee	Meta — bitexte miné du web	OPUS
OPUS-bible-uedin	ee–en, ee–fr	traductions bibliques	OPUS
OPUS-TED2020	en–fr	sous-titres TED (humain)	OPUS
OPUS-Tatoeba	en–fr	phrases communautaires	OPUS
OPUS-News-Commentary	en–fr	commentaires d'actualité	OPUS
OPUS-translatewiki	ee–fr	localisation logicielle	OPUS
google/SMOL	en–ee	Google — traductions pro.	HF Hub
FLORES-200 (dev)	fr/en/ewe	Meta — benchmark aligné (éval)	HF Hub
MAFAND (lafand-mt)	fr–ewe	Masakhane — actualités	GitHub

Table 1 : Provenance des sources. Toutes sont publiques et citables ; le corpus Ghana NLP (en–ewe, biblique) a été écarté pour cause de biais.

L'apport du projet n'est donc pas la collecte brute, mais l'**ingénierie de données** : agrégation, alignement, filtrage et contrôle du biais (sections suivantes).

3.2 Nettoyage et normalisation

Chaque phrase est nettoyée (suppression des caractères de contrôle et des artefacts de balisage), puis **normalisée en Unicode** afin d'unifier les multiples représentations possibles des caractères éwé accentués et des signes diacritiques. Cette normalisation est essentielle : sans elle, deux occurrences visuellement identiques d'un même mot éwé peuvent être encodées différemment et fausser à la fois l'apprentissage et l'évaluation.

3.3 Alignement et filtrage du bruit

Les paires web-minées subissent un filtrage en plusieurs passes :

1. **Alignement par similarité cosinus.** Chaque phrase est encodée par l'encodeur de NLLB ; on ne conserve une paire que si la similarité cosinus entre la source et la cible dépasse un seuil. Cela élimine les paires mal appariées.
2. **Identification de langue (LID).** Un filtre fastText (modèle NLLB-LID) écarte les phrases dans la mauvaise langue. La LID seule étant peu fiable sur l'éwé en textes courts, elle est **complétée d'une heuristique de caractères éwé** : on vérifie la présence de lettres propres à la langue (ɖ ƒ ŋ ɔ ɛ ɣ ʋ), ce qui réduit fortement la confusion avec l'anglais.
3. **Déduplication** des paires identiques, puis **durcissement du seuil** cosinus sur les sources les plus bruitées avant la construction finale.

3.4 Tokenisation

La tokenisation n'est pas réimplémentée : elle est déléguée au tokenizer **SentencePiece** de NLLB, un modèle de sous-mots de type *unigram*. Ce choix est cohérent avec le modèle utilisé et présente deux avantages décisifs pour l'éwé : il ne dépend pas du découpage par espaces, et il gère les mots inconnus en les décomposant en sous-unités. La langue source et la langue cible sont injectées directement dans la tokenisation au moyen des codes `fra_Latn`, `eng_Latn` et `ewe_Latn`, ce qui permet au même modèle de traiter les six directions.

3.5 Découpage et volumétrie

Le corpus est découpé en `train`/`valid`/`test` une fois pour toutes, et ce découpage est **réutilisé à l'identique** dans toutes les expériences : aucune phrase du test ou de la validation n'apparaît à l'entraînement, ce qui garantit l'absence de fuite et la comparabilité des scores.

L'entonnoir de données résume les volumes à chaque étape : plus de deux millions de

paires candidates ont été traitées, ramenées à environ un million de paires *exploitables* après filtrage, puis volontairement **plafonnées** pour équilibrer les six directions. La quantité visée n'est pas le volume brut mais une quantité *propre et équilibrée*.

Étape	Paires
Collecté / traité (toutes sources)	≈ 2 000 000
Après alignement cosinus, LID et filtre éwé	1 090 357
Après filtres anti-bruit	1 088 846
Après déduplication	1 064 356
Bidirectionnalisation (×2)	2 128 712
Après plafond de 120 000 / direction	**697 744**
dont train 669 904 • validation 13 853 • test 13 987	

Table 2 : Entonnoir de données : du brut collecté au corpus final équilibré. Environ 1,4 million de paires *exploitables* ont été écartées par choix d'équilibrage (plafond par direction).

Split	EN→EWE	EN→FR	EWE→EN	EWE→FR	FR→EN	FR→EWE	Total
Train	104 499	115 223	104 499	115 184	115 223	115 276	**669 904**
Validation : 13 853 paires • Test : 13 987 paires							

Table 3 : Volumétrie du corpus trilingue final. Les six directions sont volontairement équilibrées.

3.6 Contrôle du biais

Un risque majeur sur l'éwé est le **biais de domaine biblique** : une grande partie des corpus disponibles provient de traductions religieuses, dont le vocabulaire et le style ne reflètent pas la langue courante. Deux mesures l'atténuent : chaque paire porte un drapeau `is_religious` permettant de quantifier et de plafonner cette part (limitée à **36 530** lignes au train, soit environ **5,5 %**) ; et le corpus **Ghana NLP** (en–ewe, d'origine essentiellement biblique et fortement biaisé) a été **écarté** du jeu final.

4 Modèle de traduction

4.1 Modèle de base : NLLB-200

Le système s'appuie sur `facebook/nllb-200-distilled-600M`, une version distillée (600 millions de paramètres) du modèle *No Language Left Behind* de Meta. C'est un Transformer encodeur–décodeur entraîné sur 200 langues, dont l'éwé. La version distillée offre le meilleur compromis entre qualité et coût : elle tient sur un seul GPU grand public et reste rapide en inférence, ce qui est indispensable pour une application interactive.

4.2 Adaptation par LoRA

Affiner les 600 millions de paramètres serait coûteux et risquerait l'oubli catastrophique des connaissances multilingues du modèle. On emploie donc **LoRA** (*Low-Rank Adaptation*) : on **gèle entièrement** le modèle de base et on n'apprend que de petites matrices de rang faible, insérées dans les couches d'attention et les couches *feed-forward*. Seuls quelques pour cent des paramètres sont entraînés, ce qui réduit massivement la mémoire et le temps de calcul, tout en préservant le socle pré-entraîné. La matrice d'embedding et la tête de sortie restent gelées : la tokenisation et les représentations de NLLB ne sont donc pas dégradées.

Hyperparamètre	Valeur et justification
Modèle de base	`facebook/nllb-200-distilled-600M` (encodeur–décodeur, 200 langues).
Rang LoRA	$r = 32$, $\alpha = 64$, dropout $0{,}05$ — capacité suffisante pour apprendre à générer l'éwé.
Modules adaptés	`q_proj,k_proj,v_proj,out_proj,fc1,fc2` — attention *et* feed-forward.
Époques	2 (soit 6 250 pas) — au-delà, la perte de validation plafonne.
Lot effectif	64 (32×2 accumulations de gradient).
Taux d'apprentissage	2×10^{-4}, avec *warmup* de 3 %.
Précision	bf16 + *gradient checkpointing* pour tenir en mémoire GPU.
Longueur de séquence	128 tokens en source et en cible.
Sélection	*load best model* : on conserve le point de contrôle de meilleure `eval_loss`.

Table 4 : Configuration d'entraînement de l'adaptateur LoRA et justifications.

4.3 Dynamique d'entraînement

La perte de validation décroît de façon **monotone** tout au long des deux époques, sans aucun rebond — signe d'une bonne généralisation et de l'absence de sur-apprentissage.

Elle baissait encore légèrement en fin d'entraînement, ce qui suggère une marge résiduelle (cf. perspectives). Le mécanisme *load best model* garantit que l'on conserve le meilleur état même en cas de léger sur-apprentissage tardif.

Pas	Époque	Perte de validation
1 000	0,32	1,1487
3 000	0,96	1,1273
5 000	1,60	1,1184
6 250	2,00	**1,1165**

Table 5 : Décroissance régulière de la perte de validation (extraits).

4.4 Augmentation par back-translation

Pour renforcer les directions *vers l'éwé*, les plus pauvres en données, on applique la **back-translation**. Le principe : conserver l'**éwé humain en cible** (donc de qualité garantie) et fabriquer une **source synthétique** à l'aide du modèle déjà entraîné, uniquement à partir des paires propres `(ewe,fr)` du train. Trois jeux sont produits :

— **A** (`fr` → `en`) : génère des paires `en_synth` → `ewe` et enrichit ainsi la direction EN→EWE en contenu varié et non biblique.

— **A2** (réutilisation) : le même anglais synthétique sert à créer `ewe` → `en_synth`, ce qui équilibre EWE→EN sans calcul GPU supplémentaire.

— **B** (`ewe` → `fr`) : génère des paires `fr_synth` → `ewe` pour renforcer FR→EWE et réduire l'*off-target* (sortie en mauvaise langue).

Seules les cibles éwé **pristines** (similarité cosinus élevée *et* présence de caractères éwé) alimentent ce processus, afin de ne pas injecter de bruit. Le modèle augmenté est entraîné dans un dossier distinct, puis **comparé** au modèle sans augmentation selon une **règle d'adoption stricte** : ne retenir la back-translation que si elle améliore en↔ewe *sans* régresser ailleurs. Les résultats de cette comparaison sont présentés dans la section *Évaluation*.

5 Évaluation

5.1 Métriques

Deux métriques complémentaires sont utilisées via la bibliothèque `sacrebleu` :

— **BLEU** mesure le recouvrement de n-grammes de *mots* entre la prédiction et la référence. C'est la métrique historique, comparable à la littérature.

— **chrF** mesure le recouvrement de n-grammes de *caractères*. Elle est particulièrement pertinente pour l'éwé, langue à morphologie riche et à diacritiques, où une métrique au mot pénalise injustement de petites variations.

La génération utilise une recherche en faisceau (*beam search*) à 4 faisceaux.

5.2 Protocole

L'évaluation est conduite sur deux jeux, par direction :

— **Test interne** (`nllb_test.csv`) : issu de la même distribution que l'entraînement. Utile, mais **optimiste**.

— **FLORES-200** (`devtest`) : jeu de référence multilingue de Meta, **jamais vu** à l'entraînement et aligné dans les trois langues. C'est la mesure **claire** et comparable à l'état de l'art, y compris pour en↔ewe.

5.3 Résultat principal : base vs LoRA sur FLORES-200

La comparaison oppose le NLLB de base (adaptateur désactivé) à notre adaptateur LoRA, sur exactement les mêmes phrases. L'adaptateur **améliore les six directions**. Ces scores mesurent l'apport du fine-tuning (NLLB → LoRA) ; le modèle final y ajoute la **back-translation** (présentée plus haut), qui renforce encore les directions vers l'éwé — sa mesure sur FLORES reste une perspective.

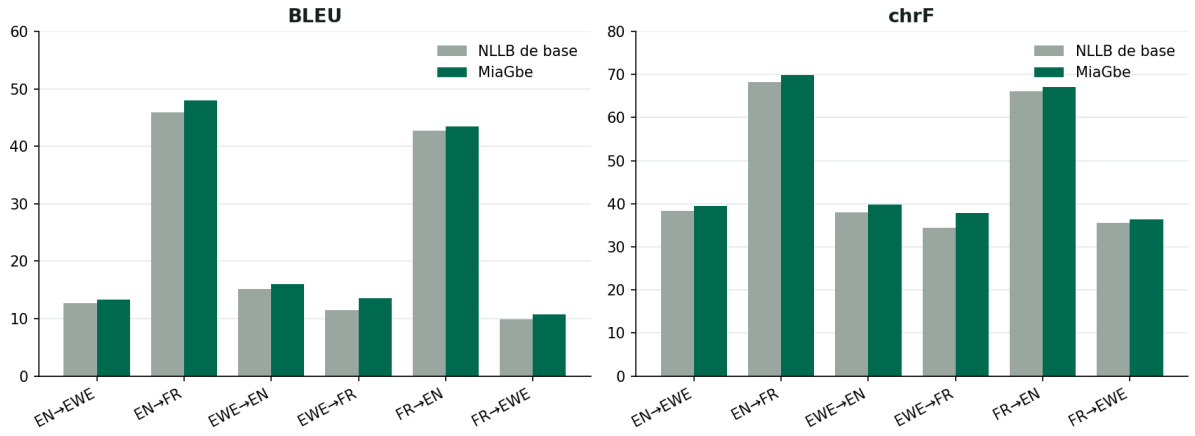


Figure 1 : FLORES-200 `devtest` : NLLB de base vs MiaGbe (BLEU et chrF, 200 phrases par direction). Le fine-tuning améliore les six directions ; moyenne +1,24 BLEU et +1,64 chrF.

5.4 Test interne

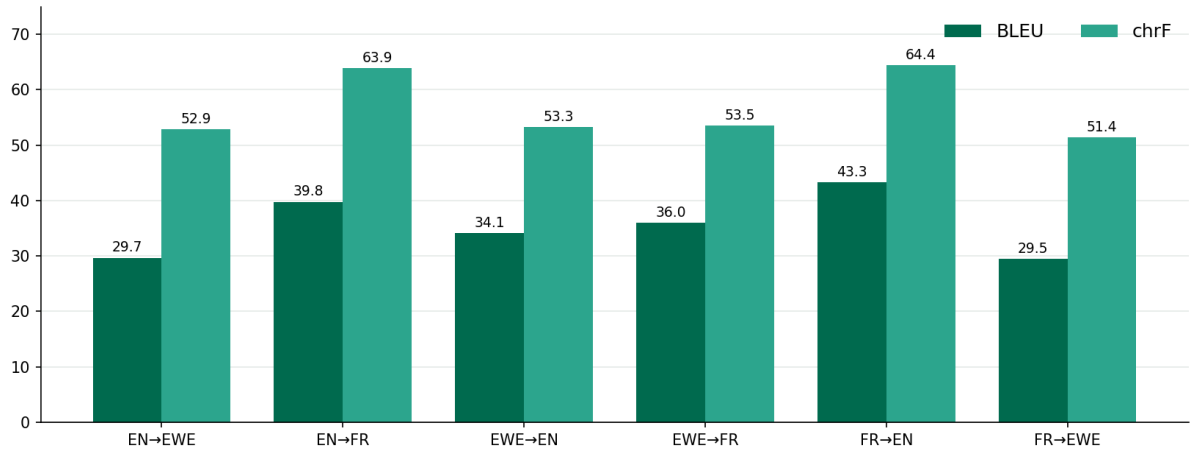


Figure 2 : Scores du modèle LoRA sur le test interne, issu de nos données (BLEU et chrF par direction ; avant back-translation). La back-translation relève encore les directions vers l'éwé.

5.5 Apport de la back-translation

La règle d'adoption (gagner sur en↔ewe sans régresser ailleurs) est **vérifiée** : les directions vers l'éwé progressent nettement — EN→EWE **+3,1** BLEU et FR→EWE **+1,4** BLEU — tandis que les autres restent stables. La back-translation est donc **retenue pour le modèle final**.

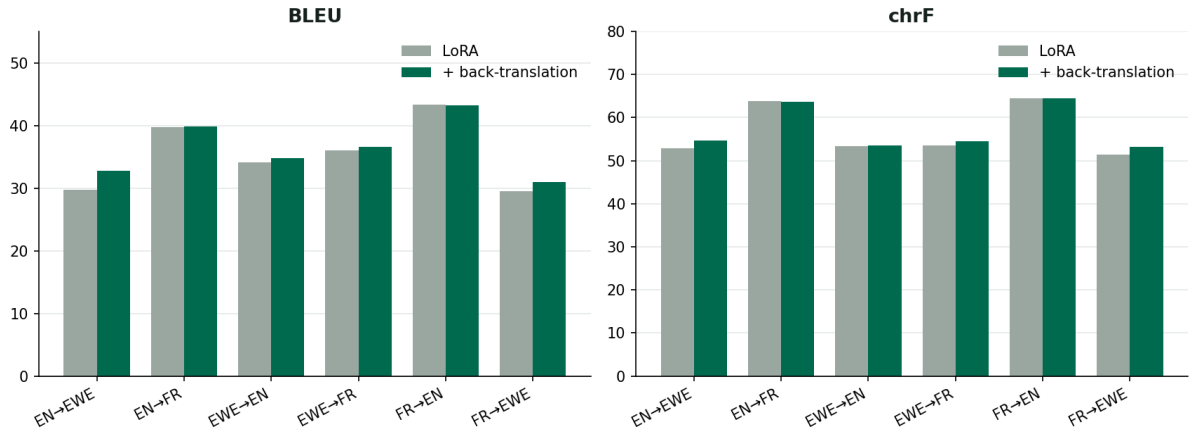


Figure 3 : Apport de la back-translation : adaptateur LoRA seul vs LoRA + back-translation, sur le test interne (BLEU et chrF). Les directions vers l'éwé progressent nettement (EN→EWE +3,1 ; FR→EWE +1,4 BLEU), sans régression ailleurs.

Réserve : ce gain est mesuré sur le test interne (optimiste) ; sa confirmation sur FLORES-200 reste une étape à mener.

5.6 Analyse

— **Aucune régression.** Sur le benchmark externe, le fine-tuning aide les six directions à la fois (+1,24 BLEU et +1,64 chrF en moyenne). C'est le résultat le plus solide et le plus défendable du projet.

— **Back-translation décisive.** Sur le test interne, l'augmentation gagne **+3,1 BLEU** en EN→EWE et **+1,4** en FR→EWE, sans régression ailleurs : c'est ce qui justifie son adoption pour le modèle final.

— **Écart test interne / FLORES.** Pour un même modèle (LoRA), FR→EWE atteint 29,5 BLEU en interne mais seulement 10,8 sur FLORES. Cet écart, attendu, illustre pourquoi un test proche du domaine d'entraînement est trompeur : seul FLORES donne une mesure réaliste de la généralisation.

— **Génération vers l'éwé.** Sur FLORES, les directions →EWE progressent le moins (+0,69 et +0,90 BLEU) et restent basses en valeur absolue — conséquence de la rareté des cibles éwé de qualité. La back-translation les renforce nettement, et reste le principal axe d'amélioration.

Exemple qualitatif (EN→EWE).
Source : « *Vatican City’s population is around 800.* »
Sortie du modèle : « *Vatika dukɔ fe agbɔsɔsɔ nye 800.* »
La sortie est une phrase éwé bien formée, employant correctement les caractères spécifiques de la langue.

6 Chaîne vocale

La chaîne vocale couvre les trois langues sans dépendance à un outil externe comme `ffmpeg` : le navigateur enregistre directement en WAV, décodé côté serveur par `librosa` (rééchantillonnage à 16 kHz, mono).

— **Reconnaissance vocale (STT). Whisper** (OpenAI) pour le français et l'anglais ; **MMS-ASR** (Meta, fondé sur Wav2Vec2 et couvrant plus de 1 100 langues) pour l'**éwé**, via son adaptateur de langue dédié.

— **Synthèse vocale (TTS). MMS-TTS** (Meta) pour l'éwé, que les navigateurs ne savent pas prononcer ; la voix native du navigateur pour le français et l'anglais.

Optimisations de performance : L'inférence audio s'exécute sur GPU détecté automatiquement ; les modèles sont **préchargés au démarrage** du serveur (ce qui élimine la latence du premier appel) ; l'adaptateur de langue MMS est mis en cache pour ne pas être rechargé à chaque requête ; et la transcription s'exécute hors de la boucle asynchrone, afin de ne pas bloquer le service.

7 Interface et API

Le backend FastAPI expose des endpoints clairs : `/translate` (traduction texte), `/transcribe` (reconnaissance vocale), `/synthesize` (synthèse vocale) et `/history` (historique). Le modèle de traduction et les modèles audio y sont chargés une seule fois et réutilisés.

L'interface React/Vite offre les fonctionnalités demandées par le cahier des charges :

— **Saisie texte** avec traduction quasi instantanée (déclenchée après une courte pause de frappe).

— **Dictée vocale** : enregistrement puis transcription côté serveur, unifiée pour les trois langues, avec un indicateur visuel de l'état (enregistrement, puis transcription en cours).

— **Écoute** de la traduction par synthèse vocale.

— **Historique** des traductions, synchronisé côté serveur entre navigateurs (authentification Google optionnelle).

8 Limites et perspectives

8.1 Limites

— **Génération vers l'éwé** : c'est le maillon faible (BLEU FLORES de l'ordre de 10 à 13). La disponibilité de cibles éwé de qualité reste le facteur limitant.

— **Hétérogénéité des données** : malgré le filtrage, une part de contenu biblique subsiste et le style global demeure inégal.

— **Couverture audio de l'éwé** : la qualité du STT/TTS éwé dépend des modèles MMS pré-entraînés, non affinés sur des locuteurs spécifiques.

8.2 Perspectives

— Confirmer le gain de la back-translation sur FLORES-200 (benchmark externe).

— Prolonger l'entraînement (la perte de validation baissait encore en fin de course).

— Étendre la back-translation EN→EWE à plus grande échelle.

— Augmenter le rang LoRA sur le décodeur pour accroître la capacité de génération.

— Collaborer avec des locuteurs natifs pour annoter du contenu courant — le levier le plus efficace à long terme pour une langue peu dotée.

9 Conclusion

Le projet livre un traducteur **trilingue opérationnel** sur les six directions, fondé sur le fine-tuning LoRA de NLLB-200, un corpus de près de 700 000 paires soigneusement filtrées et une augmentation par back-translation. Sur le benchmark externe FLORES-200, l'adaptateur **surpasse le modèle de base dans toutes les directions** (+1,24 BLEU, +1,64 chrF en moyenne), sans aucune régression. La chaîne vocale — éwé compris — et l'interface web complètent une solution de bout en bout, conforme aux livrables attendus.

La principale marge de progrès demeure la génération vers l'éwé, contrainte par la disponibilité des données : un défi inhérent aux langues peu dotées, que ce travail documente, mesure et adresse explicitement par sa méthodologie de données et d'augmentation.